

2026 年 1 月 7 日

1 基于时序网络+最优传输的显微细胞追踪方法

1.1 背景

时间序列显微成像（如荧光显微或相差显微）可以在较长时间尺度上观测单个细胞的运动与分裂过程，但在算法层面，如何在相邻帧之间为每一个细胞找到其真实对应仍然困难，尤其是在以下特殊场景中：

- 细胞密度高、局部结构高度相似；（局部同质性极高）
- 存在噪声、遮挡、分割误差；（最终均体现为分割误差，分割是最终的基础）
- 存在细胞分裂、死亡过程，或者细胞运动至视野之外；（本质上就是细胞从视野中出现或者消失，这类关键过程的追踪失效，会带来大幅误差扩散）
- 成像时间分辨率不足；（如果采样频率太低，会导致无法进行有效追踪）

经典做法通常将细胞追踪视为一个数据关联或轨迹重构问题：在时间展开图（time-expanded graph）上，以细胞为节点、以跨帧关联为边，构造一个组合优化问题（例如最小代价流或多标号分配），通过匈牙利算法、min-cost flow 等离散优化方法求解。其本质是：给定一套代价函数 $c(i \rightarrow j)$ ，希望在所有可能的跨帧匹配方案中，找到总代价最小且满足细胞基本运动和生长先验。

最优传输（Optimal Transport, OT）提供了一个连续、测度论的统一视角：不再从单点出发直接做“点对点匹配”，而是将每一帧的细胞群体视为特征空间上的经验测度，在这些测度之间寻找一份运输计划，以最小化整体的“运输成本”。在这个视角下：

- 每一帧的细胞集合 $\{c_i^t\}$ 形成一组支持点 (support);
- 每个细胞携带一定“质量” (mass), 可由细胞尺寸或其他权重确定;
- OT 传输计划 Γ^t 给出的不是单一硬匹配, 而是从源帧到目标帧的一份质量流;
- 离散数据关联问题可以看作 OT 的一个极端情形: **所有质量不可分割、每个节点的流出/流入受到硬约束。**

从这一点出发, 我们可以将显微细胞追踪自然地建模为“相邻时间点上的细胞测度之间的 (非平衡) OT”, 并将得到的传输计划解释为时间展开网络上的“最小代价流的连续松弛 (relaxation)”。

1.2 帧内表示: 经验测度与邻域图

假设通过深度学习分割模型, 我们在第 t 帧中检测到 n_t 个细胞:

$$\{c_i^t\}_{i=1}^{n_t},$$

对于每个细胞, 我们至少知道:

- 空间质心 (或几何中心) $x_i^t \in \mathbb{R}^d$, $d = 2$ 或 3 ;
- 尺寸 $s_i^t > 0$, 可以是面积 (2D) 或体积 (3D)。

经验测度表示。 将每一帧看成特征空间上的有限测度。最简单 (且与物理直觉一致) 的方式是让质量与尺寸成正比:

$$a_i^t = \frac{s_i^t}{\sum_{k=1}^{n_t} s_k^t}, \quad \mu_t = \sum_{i=1}^{n_t} a_i^t \delta_{f_i^t}, \quad (1)$$

其中 $\delta_{f_i^t}$ 为特征向量 f_i^t 处的 Dirac 测度。在基础设置下, 我们取

$$f_i^t = [x_i^t, s_i^t] \in \mathbb{R}^{d+1}, \quad (2)$$

即用“位置 + 尺寸”作为最小特征; 在可扩展版本中, 可以将局部像素强度统计、patch 级 CNN 嵌入等拼接到 f_i^t 中。

对第 $t+1$ 帧可同样定义

$$a_j^{t+1} = \frac{s_j^{t+1}}{\sum_{\ell=1}^{n_{t+1}} s_\ell^{t+1}}, \quad \mu_{t+1} = \sum_{j=1}^{n_{t+1}} a_j^{t+1} \delta_{f_j^{t+1}}. \quad (3)$$

帧内邻域图与几何结构。 除了点级特征，显微图像还包含局部细胞排列结构信息。为在 OT 中利用这些结构，我们为每一帧构造帧内图 G_t ：

$$G_t = (V_t, E_t, W_t), \quad V_t = \{1, \dots, n_t\}. \quad (4)$$

一种常用构图方式是按质心的 k 近邻建图：

$$E_t = \{(i, k) \mid x_k^t \in \text{kNN}(x_i^t)\}, \quad (5)$$

边权同时考虑空间与特征相似性：

$$w_{ik}^t = \exp\left(-\frac{\|x_i^t - x_k^t\|_2^2}{\sigma_x^2} - \frac{\|f_i^t - f_k^t\|_2^2}{\sigma_f^2}\right), \quad (i, k) \in E_t. \quad (6)$$

此外，我们定义帧内距离矩阵 $D^t \in \mathbb{R}_+^{n_t \times n_t}$ ：

$$D_{ik}^t = \|x_i^t - x_k^t\|_2, \quad i, k \in V_t, \quad (7)$$

也可以选择图上的测地距离（例如最短路径长度）来更好地反映局部拓扑结构。综上，每一帧由 (μ_t, D^t) 描述，其中 μ_t 抽象了细胞分布， D^t 抽象了局部几何关系。

1.3 相邻帧之间的最优传输耦合

给定相邻两帧 t 与 $t+1$ ，我们希望构造一个非负矩阵

$$\Gamma^t \in \mathbb{R}_+^{n_t \times n_{t+1}},$$

其中 Γ_{ij}^t 表示从帧 t 中的细胞 c_i^t 向帧 $t+1$ 中的细胞 c_j^{t+1} 传输的质量。直观理解：如果某个生物细胞在两帧之间连续存在，则其对应的质量应被从 i 传输到 j ；如果细胞死亡，质量会在 t 帧“消失”；新生细胞则在 $t+1$ 帧“凭空出现”。

基于几何与尺寸的特征代价。 首先定义一个代价矩阵 $C^{\text{feat}} \in \mathbb{R}^{n_t \times n_{t+1}}$ ，用于惩罚空间位移过大或尺寸变化不合理的匹配：

$$C_{ij}^{\text{feat}} = \alpha \|x_i^t - x_j^{t+1}\|_2^2 + \beta \left(\frac{s_i^t - s_j^{t+1}}{\sigma_s} \right)^2, \quad 1 \leq i \leq n_t, 1 \leq j \leq n_{t+1}, \quad (8)$$

其中 $\alpha, \beta > 0$ 控制“位移代价”和“尺寸变化代价”的相对权重, σ_s 用于尺寸归一。为了显式编码速度上界并降低计算量, 我们只考虑空间距离不超过阈值 $R_{\max}$ 的候选对:

$$\|x_i^t - x_j^{t+1}\|_2 > R_{\max} \Rightarrow C_{ij}^{\text{feat}} = +\infty,$$

这样可以直接在成本层面排除位移明显不合理的匹配。

融合特征与结构的 Fused Gromov–Wasserstein 代价。 仅依靠点级特征差异在密集场景中易受局部噪声影响。考虑到我们已在每一帧构造了几何结构 D^t 与 D^{t+1} , 可以引入一种“特征 + 结构”融合的 OT 代价, 形式上接近 Fused Gromov–Wasserstein (FGW)。具体写作:

$$\begin{aligned} \mathcal{L}(\Gamma^t) = & (1 - \eta) \sum_{i,j} C_{ij}^{\text{feat}} \Gamma_{ij}^t \\ & + \eta \sum_{i,k=1}^{n_t} \sum_{j,\ell=1}^{n_{t+1}} (D_{ik}^t - D_{j\ell}^{t+1})^2 \Gamma_{ij}^t \Gamma_{k\ell}^t, \end{aligned} \quad (9)$$

其中 $\eta \in [0, 1]$ 控制特征项与结构项的相对重要性:

- 当 $\eta = 0$ 时, 退化为纯特征匹配的 W-type OT;
- 当 $\eta > 0$ 时, 第二项鼓励“保持对之间的距离结构”: 如果在帧 t 中两细胞 i, k 距离较近, 则其匹配到帧 $t+1$ 中的 j, ℓ 也应保持相似的距离 $D_{j\ell}^{t+1}$ 。

这等价于在 OT 中显式惩罚“局部结构扭曲”, 使得局部细胞簇更倾向于整体移动, 而不是各点独立乱跳。

熵正则和平衡 OT。 在最严格的质量守恒假设下, 我们要求:

$$\sum_{j=1}^{n_{t+1}} \Gamma_{ij}^t = a_i^t, \quad \forall i, \quad \sum_{i=1}^{n_t} \Gamma_{ij}^t = a_j^{t+1}, \quad \forall j. \quad (10)$$

这意味着从帧 t 的第 i 个细胞流出的总质量等于其初始质量 a_i^t , 帧 $t+1$ 中第 j 个细胞接收到的总质量等于其质量 a_j^{t+1} , 整体上 $\sum_i a_i^t = \sum_j a_j^{t+1} = 1$ 。

引入熵正则以获得数值上更稳定、且可用 Sinkhorn 类算法高效求解的解:

$$\text{Ent}(\Gamma^t) = \sum_{i=1}^{n_t} \sum_{j=1}^{n_{t+1}} \Gamma_{ij}^t (\log \Gamma_{ij}^t - 1). \quad (11)$$

于是，相邻帧之间的平衡 OT 问题为：

$$\begin{aligned} \min_{\Gamma^t \geq 0} \quad & \mathcal{L}(\Gamma^t) + \varepsilon \text{Ent}(\Gamma^t) \\ \text{s.t.} \quad & \Gamma^t \mathbf{1} = a^t, \quad (\Gamma^t)^\top \mathbf{1} = a^{t+1}, \end{aligned} \quad (12)$$

其中 $\varepsilon > 0$ 控制熵平滑的强度， $\mathbf{1}$ 为全 1 向量。 $\mathcal{L}$ 在特征与结构层面约束匹配合理性，熵项则防止解过于离散，有利于梯度型或 Sinkhorn 型优化。

非平衡 OT：支持出生、死亡与分裂。 真实数据中，帧间往往存在细胞死亡、脱离视野、进入视野以及分裂等事件，此时总质量并不必守恒。我们采用非平衡 OT (unbalanced OT) 框架，将严格的边缘约束替换为 KL 散度惩罚。对非负向量 u, v 定义：

$$\text{KL}(u \parallel v) = \sum_i u_i \log \frac{u_i}{v_i} - u_i + v_i. \quad (13)$$

则非平衡 OT 问题为：

$$\begin{aligned} \min_{\Gamma^t \geq 0} \quad & \mathcal{L}(\Gamma^t) + \varepsilon \text{Ent}(\Gamma^t) \\ & + \tau_t \text{KL}(\Gamma^t \mathbf{1} \parallel a^t) + \tau_{t+1} \text{KL}((\Gamma^t)^\top \mathbf{1} \parallel a^{t+1}), \end{aligned} \quad (14)$$

其中 $\Gamma^t \mathbf{1}$ 为每个源细胞实际流出的总质量向量， $(\Gamma^t)^\top \mathbf{1}$ 为每个目标细胞收到的总质量向量， $\tau_t, \tau_{t+1} > 0$ 控制对“质量守恒”的惩罚力度：

- 当 $\tau_t, \tau_{t+1} \rightarrow \infty$ 时，逼近平衡 OT；
- 当 τ_t, τ_{t+1} 较小时，允许大规模出生/死亡/分裂。

直观解释：

- 若某源细胞 c_i^t 的行和 $\sum_j \Gamma_{ij}^t$ 明显小于 a_i^t ，可以解释为该细胞在此帧之后死亡或离开视野；
- 若某目标细胞 c_j^{t+1} 的列和 $\sum_i \Gamma_{ij}^t$ 明显小于 a_j^{t+1} ，则可解释为其为新进入视野的细胞；
- 若某源细胞 c_i^t 对多个目标细胞分配了显著质量（且这些目标细胞的尺寸之和与 s_i^t 基本一致），则对应一次细胞分裂事件。

若希望进一步将“细胞增长/分裂先验”纳入目标，还可以在 a^t 上引入逐细胞的生长因子 g_i^t ，将 a^t 替换为 $g^t \odot a^t$ ，从而在 KL 项中对“预期分裂/死亡”的细胞赋予不同的惩罚强度，这里不再展开。

1.4 与时序网络的理论关联

上面的 OT 耦合 $\{\Gamma^t\}_{t=1}^{T-1}$ 自然诱导出一张时间展开的细胞时序网络。定义时间标记的节点集合：

$$\mathcal{V} = \bigcup_{t=1}^T \{(i, t) \mid i \in V_t\}, \quad (15)$$

帧内边仍由 E_t 给出（刻画同一时间点的空间邻接）；跨帧边则由 OT 传输计划的支撑确定：

$$\mathcal{E}_{\text{inter}} = \bigcup_{t=1}^{T-1} \{(i, t) \rightarrow (j, t+1) \mid \Gamma_{ij}^t > 0\}. \quad (16)$$

将跨帧边赋权

$$w_{(i,t) \rightarrow (j,t+1)}^{\text{inter}} = \Gamma_{ij}^t,$$

则得到一张时间有向网络，其中“质量”沿时间轴不断向前流动。注意到：

- 在平衡情形下，节点 (i, t) 的流出总量等于 a_i^t ，节点 $(j, t+1)$ 的流入总量等于 a_j^{t+1} ；
- 在非平衡情形下，上述关系被软化为 KL 惩罚。

从图论角度看，式 (12) 和 (14) 可以理解为在时间展开图上的最小代价流问题的连续松弛：

- 边成本由特征代价 C^{feat} 和结构代价（ D^t 与 D^{t+1} 的差异）共同决定；
- 节点的流守恒约束被用硬约束（平衡 OT）或软惩罚（非平衡 OT + KL）表达。

进一步地，可以将所有相邻帧的传输计划放在一个全局目标中统一优化，加入跨时间的平滑正则：

$$\begin{aligned} \min_{\{\Gamma^t\}_{t=1}^{T-1}} \quad & \sum_{t=1}^{T-1} \left[\mathcal{L}(\Gamma^t) + \varepsilon \text{Ent}(\Gamma^t) + \tau_t \text{KL}(\Gamma^t \mathbf{1} \parallel a^t) + \tau_{t+1} \text{KL}((\Gamma^t)^\top \mathbf{1} \parallel a^{t+1}) \right] \\ & + \lambda_{\text{temp}} \sum_{t=1}^{T-2} \mathcal{R}_{\text{temp}}(\Gamma^t, \Gamma^{t+1}), \end{aligned} \quad (17)$$

其中 $\lambda_{\text{temp}} \geq 0$ 控制时间平滑强度。一个合理的选择是使用“两步复合耦合”的一致性作为正则：

$$\mathcal{R}_{\text{temp}}(\Gamma^t, \Gamma^{t+1}) = \|\Gamma_{\text{direct}}^{t,t+2} - \Gamma^t \Gamma^{t+1}\|_F^2, \quad (18)$$

其中 $\Gamma^t \Gamma^{t+1} \in \mathbb{R}^{n_t \times n_{t+2}}$ 表示通过连乘得到的“从 t 到 $t+2$ 的两步传输”， $\Gamma_{\text{direct}}^{t,t+2}$ 则是通过在帧 t 与帧 $t+2$ 之间直接解一个（可在空间上适当粗化的）OT 问题得到的耦合。两者的差异用 Frobenius 范数来衡量。该项鼓励“一步耦合”在多步复合时保持时间上的 Markov 一致性，避免局部最优导致的局部轨迹不连贯。

在此基础上，如果将每一行 Γ_i^t 归一化为条件概率

$$P((j, t+1) | (i, t)) = \frac{\Gamma_{ij}^t}{\sum_{j'} \Gamma_{ij'}^t + \delta},$$

（ $\delta > 0$ 为防止除零），则 $\{\Gamma^t\}$ 诱导出一个时间非齐次 Markov 链，定义在细胞标记的状态空间上。对于任意一条长度为 L 的轨迹

$$\pi = (i_1, t_1) \rightarrow (i_2, t_2) \rightarrow \cdots \rightarrow (i_L, t_L),$$

其路径概率可写为

$$P(\pi) = \prod_{\ell=1}^{L-1} P((i_{\ell+1}, t_{\ell+1}) | (i_{\ell}, t_{\ell})),$$

从而在时间展开图上自然定义了一族路径分布。长程到达概率由多步连乘给出，可以用来衡量“某个细胞在未来若干帧到达某一空间位置或谱系状态”的不确定性，这为后续的谱系推断和集体动力学分析提供了概率论基础。

从时序网络的角度看，上述构造使得细胞追踪不再是孤立的相邻帧匹配问题，而是通过在时间展开图上约束多步路径的一致性和整体代价，显式利用了时序网络在长程依赖建模中的优势。

1.5 长程一致性与遮挡处理

仅依赖相邻帧的 OT 耦合虽然能很好地解决短程匹配问题，但在长时间尺度下，误差容易逐帧积累，尤其是在：

- 细胞密度极高、局部结构高度重复，导致局部匹配存在多解；

- 某些细胞在若干帧中被遮挡或暂时分割失败，之后又重新出现；
- 细胞群体整体发生缓慢漂移或形变时，

单纯的“逐对帧独立 OT + 贪心串联”难以保证长程轨迹的稳定性。本节在上述框架基础上，进一步引入长程一致性约束与简单运动先验，以缓解这一问题。

多尺度时间耦合与跳帧一致性。 式 (17) 中的 $\mathcal{R}_{\text{temp}}$ 仅约束了两步复合耦合 $\Gamma^t \Gamma^{t+1}$ 与直接两帧耦合 $\Gamma_{\text{direct}}^{t,t+2}$ 之间的一致性。为了更强的长程约束，可以引入多尺度时间耦合：对更长的时间间隔 $k > 1$ ，在粗分辨率下直接求解帧 t 与帧 $t+k$ 间的 OT 耦合 $\Gamma_{\text{direct}}^{t,t+k}$ ，并将其与多步复合

$$\Gamma^t \Gamma^{t+1} \dots \Gamma^{t+k-1} \in \mathbb{R}^{n_t \times n_{t+k}}$$

进行比较。例如，可以将时间正则扩展为

$$\mathcal{R}_{\text{temp}}^{(k)}(\Gamma^t, \dots, \Gamma^{t+k-1}) = \left\| \Gamma_{\text{direct}}^{t,t+k} - \Gamma^t \Gamma^{t+1} \dots \Gamma^{t+k-1} \right\|_F^2, \quad (19)$$

并在全局目标中附加

$$\sum_{k \in \mathcal{K}} \lambda_{\text{temp}}^{(k)} \sum_t \mathcal{R}_{\text{temp}}^{(k)}(\Gamma^t, \dots, \Gamma^{t+k-1}),$$

其中 $\mathcal{K}$ 是若干时间尺度（如 $\{2, 3, 5\}$ ）， $\lambda_{\text{temp}}^{(k)}$ 为对应权重。这样不仅要求“相邻两步”是局部最优，还要求在更长时间跨度上，轨迹的统计行为与“长间隔 OT”一致，从而在全局上抑制逐帧小误差的长期累积。在工程实现上， $\Gamma_{\text{direct}}^{t,t+k}$ 可以在下采样的空间网格或抽样子集上求解，以控制计算复杂度。

运动先验与速度约束。 当前的特征代价 C_{ij}^{feat} 仅依赖单步位移 $\|x_i^t - x_j^{t+1}\|$ ，隐含假设是“每一帧之间的运动相互独立”。为了增强长程稳定性，可以显式引入简单的运动先验（例如近似匀速运动），通过上一帧得到速度估计并对下一帧施加约束。

假设已经通过上一轮追踪在帧 $t-1$ 与帧 t 之间建立了硬关联 $p(i)$ ，即 $c_{p(i)}^{t-1}$ 是 c_i^t 的前驱，则可以估计速度

$$v_i^t \approx x_i^t - x_{p(i)}^{t-1}, \quad (20)$$

并据此预测下一帧的位置：

$$\hat{x}_i^{t+1} = x_i^t + v_i^t. \quad (21)$$

在此基础上，将特征代价扩展为

$$\tilde{C}_{ij}^{\text{feat}} = \alpha \|x_i^t - x_j^{t+1}\|_2^2 + \alpha' \|\hat{x}_i^{t+1} - x_j^{t+1}\|_2^2 + \beta \left(\frac{s_i^t - s_j^{t+1}}{\sigma_s} \right)^2, \quad (22)$$

其中 $\alpha' > 0$ 控制运动先验的重要性。该设计鼓励候选后继细胞不仅在当前位置上接近 x_i^t ，还应靠近基于历史轨迹推断的预测位置 $\hat{x}_i^{t+1}$ 。实作中只需在原有 C^{feat} 基础上增加一项，不改变求解器形式。下文如无特殊说明， C^{feat} 均可理解为包含这一运动先验的扩展版本。

当轨迹已经稳定建立时，速度先验会为其提供“惯性”，从而在长时间尺度上减少轨迹身份逐步漂移的可能性；在遮挡或短暂分割失败的情况下，速度先验也有助于在后续帧中重新捕捉到同一生物细胞。

短轨迹片段与第二层 OT。 在复杂场景中，可以将 OT 追踪分为两个时间尺度：短时间尺度上建立可靠的短轨迹片段（tracklet），长时间尺度上再对 tracklet 之间进行关联。具体而言：

1. 在一个较短的滑动时间窗口（如 3–5 帧）内，采用上述 OT 框架（含 FGW 结构项与运动先验）求解 Γ^t ，并通过较严格的阈值筛选，只保留置信度较高的跨帧关联，形成局部 tracklet；
2. 将每个 tracklet 视作一个“超级节点”，为其定义汇总的特征（例如 tracklet 中所有细胞位置的均值轨迹、平均速度、整体尺寸变化等），在更长时间范围内构建 tracklet 级别的测度与代价，再通过第二层 OT 或最小代价流将这些 tracklet 串联起来。

这一分层策略可以视为在时间上进行 coarse-graining：第一层在高时间分辨率下解决局部匹配问题，第二层在低时间分辨率下解决长程关联问题。由于第二层的节点数远小于原始细胞数，其 OT 代价在计算上是可控的，而在逻辑上则对长程轨迹提供了额外的一致性约束和遮挡恢复能力。

从时序网络角度看，以上扩展都是在时间展开图上对多步路径的统计行为施加约束：多尺度时间耦合约束长路径的整体代价，运动先验限制路径在时间上的弯曲程度，tracklet-级二次 OT 则在更粗时间尺度上对路径进行聚合和再优化，从而发挥了时序网络在长程依赖和遮挡恢复方面的优势。

1.6 由传输计划重建细胞轨迹

求解 (12) 或 (14) 及其长程扩展后，我们得到的是软传输计划 Γ^t 。轨迹重构需要在此基础上提取硬的跨帧关联，并将其串联成时间序列。

对第 t 帧中的每个细胞 c_i^t ，在第 $t+1$ 帧中选取其最可能的后继：

$$j^*(i, t) = \arg \max_{1 \leq j \leq n_{t+1}} \Gamma_{ij}^t. \quad (23)$$

为了避免由极小的噪声质量产生伪匹配，我们仅在同时满足

$$\Gamma_{ij^*(i,t)}^t \geq \theta_\Gamma \quad \text{且} \quad C_{ij^*(i,t)}^{\text{feat}} \leq \theta_C \quad (24)$$

时，接受关联 $c_i^t \rightarrow c_{j^*(i,t)}^{t+1}$ ，其中 θ_Γ 是最小传输质量阈值， θ_C 是最大允许特征代价阈值。进一步：

- 若某源细胞的行和

$$m_i^{\text{out}} = \sum_j \Gamma_{ij}^t$$

低于阈值 η_{death} ，则将其在帧 t 标记为轨迹终止点（死亡或离视野）；

- 若某目标细胞的列和

$$m_j^{\text{in}} = \sum_i \Gamma_{ij}^t$$

低于阈值 η_{birth} ，则将其在帧 $t+1$ 标记为轨迹起点（出生或进入视野）；

- 若某源细胞对多个目标细胞分配了显著质量（如存在 j_1, j_2 使 $\Gamma_{ij_1}^t, \Gamma_{ij_2}^t$ 均超过一定比例阈值），且

$$s_{j_1}^{t+1} + s_{j_2}^{t+1} \approx s_i^t$$

在给定容差内成立，则识别为一次二分裂事件；推广可处理多分裂。

将所有相邻帧对上被接受的跨帧关联串联，即可得到完整的时间序列轨迹：

$$c_{i_1}^{t_1} \rightarrow c_{i_2}^{t_2} \rightarrow \cdots \rightarrow c_{i_L}^{t_L},$$

同时在具有多后继的节点处得到谱系分叉结构，构成一张细胞谱系图。与完全离散的“硬匹配”方法相比，这一 OT 框架的优势在于：

- 在优化层面，通过连续的质量流优化整体代价，在一定程度上避免了局部贪心带来的不一致匹配；
- 在表达层面，软耦合 Γ^t 同时给出了主路径和备选路径，为不确定性评估、轨迹修正以及与其他模态（如分子标记或转录组）的联合分析提供了丰富的信息；
- 在时间尺度上，通过多尺度时间正则与运动先验，将 OT 从局部相邻帧匹配提升为在时间展开网络上的连续最小代价流，从而在中长期尺度上缓解误差累积和遮挡导致的轨迹漂移问题。

1.7 实现与复杂度分析

上述框架在工程上是可实现的，但需要若干设计以控制计算复杂度和内存占用。

相邻帧 OT 的实现。 对于单对相邻帧 $(t, t+1)$ ，若细胞数分别为 n_t 和 n_{t+1} ，则：

- 特征代价矩阵 C^{feat} 的构造复杂度为 $O(n_t n_{t+1})$ ，可通过限制最大位移半径 $R_{\max}$ 和使用稀疏近邻结构（例如仅对 k 近邻构造代价）将其有效稀疏化；
- FGW 结构项中的四重和在最坏情况下为 $O(n_t^2 n_{t+1}^2)$ ，在实际实现中通常结合稀疏邻接（有限度地截断 D^t, D^{t+1} ）和低秩/随机近似来降低复杂度，例如只在局部邻域上计算结构项，或采用 block-wise/mini-batch 近似；
- 熵正则的（非）平衡 OT 可通过 Sinkhorn 或其非平衡扩展来求解，单次 Sinkhorn 迭代的复杂度约为 $O(\text{nnz}(K))$ ，其中 $K = \exp(-C/\varepsilon)$ ，在稀疏代价设置下可接近线性。

综合来看，在典型显微数据（每帧 10^2 – 10^3 个细胞）下，相邻帧 OT 可以在 GPU 或多核 CPU 上稳定运行；对于更大规模场景，可通过空间分块（逐块追踪并在边界区域拼接）进一步降低单次问题规模。

多尺度时间耦合的实现。 对于跳帧 OT (如 $\Gamma_{\text{direct}}^{t,t+k}$)，直接在全分辨率上求解代价较高。实际实现中可以：

- 对空间坐标进行粗网格下采样，将细胞聚合为 super-voxel，再在 super-voxel 层面解 OT；
- 或对细胞随机采样一个子集，以近似全局长程形变；
- 对 k 的取值只保留少数几个 (如 2, 3, 5)，并控制 $\lambda_{\text{temp}}^{(k)}$ 的大小，使跳帧项作为软正则而非主导项。

在数值优化时，可以采用交替优化策略：先对每对相邻帧独立求解 Γ^t 作为初始化，再在全局目标 (17) 下做少量迭代式微调，以兼顾精度与效率。

运动先验与 tracklet 级 OT 的实现。 运动先验仅在代价矩阵构造阶段增加一项额外距离计算，时间复杂度与原有 C^{feat} 同阶，不改变 OT 求解器的复杂度阶数。tracklet 级 OT 则在大幅减少节点数的前提下运行在更粗时间尺度上，其规模通常远小于原始细胞数，使得二层 OT 或 min-cost flow 可以采用现有成熟实现 (例如线性规划或图优化库) 直接求解。

总体而言，通过稀疏近邻、局部结构项、跳帧的粗分辨率 OT 以及 tracklet 层的分层优化，整个 OT+时序网络框架在工程上是可实现的，并且能够在中等规模的显微细胞追踪任务上达到可接受的时间和内存开销。

2 nn U-Net + OT + GNN

2.0.1 动态图对OT与分割误差的纠正机制

在上一小节中，基于最优传输 (OT) 我们已经为相邻两帧 $(t, t+1)$ 构造了软耦合矩阵 Γ^t 及其对应的代价矩阵 C^t (见式 (14))。本节在此基础上，说明如何利用动态图 (时间展开图) + GNN 对 OT 决策和分割误差进行系统性的校正。

从 OT 到时间展开图：候选边的生成与特征化。 首先，将所有带时间标记的细胞实例

$$\mathcal{V} = \bigcup_{t=1}^T \{(i, t) \mid c_i^t \text{ 为第 } t \text{ 帧的第 } i \text{ 个细胞}\}$$

作为图的节点。对每个节点 (i, t) 定义初始特征：

$$h_{(i,t)}^{(0)} = [x_i^t, s_i^t, f_i^t, \tilde{t}] \in \mathbb{R}^{d_x+1+d_f+1}, \quad (25)$$

其中 x_i^t 为质心坐标， s_i^t 为细胞尺寸（面积/体积）， f_i^t 为由分割网络（如 nnU-Net encoder）提取的外观特征向量， $\tilde{t}$ 是归一化的时间索引（如 t/T ）。

对于每一对相邻帧 $(t, t+1)$ ，利用 OT 软耦合 Γ^t 构造跨帧候选边集合：

$$\mathcal{E}_{\text{time}}^t = \{((i, t) \rightarrow (j, t+1)) \mid \Gamma_{ij}^t \geq \theta_\Gamma, C_{ij}^t \leq \theta_C\}, \quad (26)$$

即仅保留传输质量足够大且代价足够小的 (i, j) 对作为“合理候选”。对每条候选边 $e = ((i, t) \rightarrow (j, t+1))$ 定义初始边特征：

$$e_e^{(0)} = [C_{ij}^t, \Gamma_{ij}^t, \|x_i^t - x_j^{t+1}\|_2, s_i^t, s_j^{t+1}, \Delta t], \quad (27)$$

其中 $\Delta t = 1$ ，其他分量分别编码 OT 成本、传输质量、空间位移以及前后尺寸。为建模同一帧内的局部拓扑，可在每个 t 上构造帧内 k 近邻图：

$$\mathcal{E}_{\text{intra}}^t = \{((i, t) \leftrightarrow (k, t)) \mid x_k^t \in \text{kNN}(x_i^t)\}, \quad (28)$$

并为帧内边定义基于空间和特征差异的边特征（例如 $\|x_i^t - x_k^t\|_2$ 、 $\|f_i^t - f_k^t\|_2$ 等）。最终得到时间展开动态图

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}_{\text{time}} \cup \mathcal{E}_{\text{intra}}),$$

其中 $\mathcal{E}_{\text{time}} = \bigcup_t \mathcal{E}_{\text{time}}^t$ 。

在存在轨迹真值（如 CTC 数据集）时，针对每条时间边 $e = ((i, t) \rightarrow (j, t+1))$ ，可根据谱系标注赋予监督标签

$$y_e = \begin{cases} 1, & \text{若 } c_i^t \text{ 为 } c_j^{t+1} \text{ 的真实前驱细胞,} \\ 0, & \text{否则,} \end{cases} \quad (29)$$

用于后续 GNN 的边级二分类训练。

局部 OT 决策的残差校正与长程一致性约束。 OT 层以手工设计的代价 C_{ij}^t 为基础，只在相邻两帧 $(t, t+1)$ 上求解局部的“全局最优”质量流。受限于局部信息与代价建模误差，OT 可能在某些模糊场景下产生错配，例

如：位移、尺寸和外观都相近的多个候选目标之间难以区分，遮挡或光照变化导致特征突变等。

为此，在动态图 $\mathcal{G}$ 上引入节点-边交替更新的 GNN 结构，对 OT 输出的候选边进行残差式校正。设第 l 层的节点特征为 $h_u^{(l)}$ ，边特征为 $e_e^{(l)}$ ，则一层 GNN block 可形式化为：

$$e_{u \rightarrow v}^{(l+1)} = \phi_e(e_{u \rightarrow v}^{(l)}, h_u^{(l)}, h_v^{(l)}), \quad ((u \rightarrow v) \in \mathcal{E}), \quad (30)$$

$$\tilde{m}_v^{(l+1)} = \sum_{(u \rightarrow v) \in \mathcal{E}} e_{u \rightarrow v}^{(l+1)}, \quad (31)$$

$$h_v^{(l+1)} = \phi_h(h_v^{(l)}, \tilde{m}_v^{(l+1)}), \quad (32)$$

其中 ϕ_e, ϕ_h 为多层感知机（MLP）或带注意力机制的消息函数。堆叠 L 层后，得到最终的边嵌入 $e_e^{(L)}$ ，再通过一个边分类头

$$\hat{y}_e = \sigma(\psi(e_e^{(L)})), \quad (33)$$

对每条候选时间边是否为真实轨迹边进行预测。

在损失函数上，采用边级二元交叉熵：

$$\mathcal{L}_{\text{edge}} = - \sum_{e \in \mathcal{E}_{\text{time}}} [y_e \log \hat{y}_e + (1 - y_e) \log(1 - \hat{y}_e)], \quad (34)$$

并可引入与 OT 成本一致性的正则项，如

$$\mathcal{L}_{\text{OT-reg}} = \sum_{e \in \mathcal{E}_{\text{time}}} \hat{y}_e C_e, \quad (35)$$

其中 $C_e = C_{ij}^t$ 是对应边的 OT 成本。该项鼓励被 GNN 判为“高置信真实边”的关联同时具有较低的 OT 代价，从而保持学习决策与显式代价骨架的一致性。

在这一框架下，GNN 不再无条件接受 OT 的最大流决策，而是利用多步时间上下文与空间邻域结构对局部 OT 决策进行残差校正与长程一致性约束。例如：

- 若某条 OT 候选边导致轨迹在 $(t-1, t, t+1)$ 三帧中出现不合理的突然折返或速度剧烈变化（与历史轨迹和邻居轨迹均不一致），则通过多层消息传递，GNN 可以学习到此类“局部合理、全局异常”的模式，从而降低该边的置信度；

- 若两个候选目标在单步几何和外观上难以区分，但分别嵌入到不同的时间-空间运动簇中，GNN 可通过邻域聚合感知“群体动力学”的差异，倾向选择保持轨迹在同一运动簇内连续演化的候选边。

因此，动态图上的 GNN 实际上实现了对“仅基于两帧 OT 的短视局部最优”的全局纠偏。

分割误差的轨迹级鲁棒性建模。 前端分割（如 nnU-Net）不可避免地存在漏检（FN）、假阳性（FP）、过分割和欠分割等错误。动态图 + GNN 虽然不能直接在像素级“重画”分割，但可以在轨迹级显著减弱这些误差对下游分析的影响：

1. **漏检（FN）与遮挡：** 当某一帧 t 的真实细胞未被分割出来时，对应节点 (i, t) 在图中缺失，导致轨迹存在“空洞”。若在 OT 构图或后续轨迹拼接中允许跨帧候选，例如从 $(i, t-1)$ 直接连到 $(k, t+1)$ ，则 GNN 可在训练过程中学习到“跨一帧的平滑连接”模式，从而在图结构中通过边

$$(i, t-1) \rightarrow (k, t+1)$$

对分割空洞进行桥接，保持轨迹在时间上的连续性。此时虽然帧 t 的 mask 仍为空，但整体轨迹不会被截断，TRA 等轨迹指标得到保护。

2. **假阳性（FP）：** 假阳性 mask 一般只在少数帧短暂出现，且难以与前后真实轨迹形成平滑的一致路径。在动态图中，这类节点很难获得来自上下文和邻域的支持，其相关时间边在训练中几乎全部被标注为负样本。GNN 在训练后会自动学到“连向 FP 节点的边置信度普遍很低”的模式，推理阶段这些边被抑制，FP 节点被孤立，不会被纳入任何有效轨迹，从而在轨迹空间实现对假阳性的过滤。
3. **过分割：** 过分割时，同一真实细胞在某几帧上被划分为多个 mask，图中表现为同一时间 t 出现多个节点 $(i_1, t), (i_2, t), \dots$ 与同一前驱或后继有密集连边，导致某些节点的入/出度异常。GNN 可利用
 - 异常大的入/出度，
 - 与前后帧轨迹的一致性（仅一条路径平滑、其它路径异常折返或速度突变），

在边级别选择性地保留少数最合理的时间边，压制其余边的置信度，从而在轨迹层面“为每条真实轨迹选出一个代表节点”，显著降低过分割对 ID 切换和轨迹碎片化的影响。

4. **欠分割：** 欠分割时，多真实细胞黏连为单一大 mask，图中表现为该节点在时间上一段区间同时承担多个真实轨迹的前驱/后继角色，入/出度模式明显异常。通过对入/出度统计以及与邻域轨迹的一致性建模，GNN 可以将这类“多源/多汇”的节点标记为不可靠区域，在轨迹构建阶段通过约束“每个节点最多一个父节点、有限个子节点”的后处理规则，对其相关边进行重打分和筛选，从而在轨迹级显式标记欠分割带来的不确定区段，避免错误拓扑扩散到更长时间尺度。

综上，OT 层提供了可解释的、基于几何与外观代价的局部软匹配先验，而基于时间展开图的 GNN 则通过多步时间上下文和空间邻域信息，对 OT 决策进行残差校正与长程一致性约束；同时在轨迹层面对漏检、假阳性、过分割与欠分割等分割误差具有内在的鲁棒性，从而在整体上显著提升显微细胞追踪的稳定性与可靠性。